IIC3633 Sistemas Recomendadores

Informe Tarea 1

Alonso Casanova Bruno Cerda

10 de abril de 2026

Resumen

Índice

1. Análisis de Datos **2**
1.1. Dataset Yahoo! Music 2
1.2. Dataset Wikimedia Commons 3

2. Sistemas de Recomendación y Resultados **5**
2.1. Recomendación de Música (Yahoo! Music) 5
2.1.1. Predicción de Ratings 5
2.1.2. Generación de Listas de Recomendación (Top-N) 7
2.2. Recomendación de Imágenes (Wikimedia) 9

3. Bonuses (Opcional) **11**
3.1. Uso de calificación 255 (Yahoo! Music) 11
3.2. Uso de evaluación True/False (Wikimedia) 11
3.3. Análisis de Sustentabilidad (Green RecSys) 11
3.4. Competición 11

1. Análisis de Datos

1.1. Dataset Yahoo! Music

Comenzamos describiendo propiedades estadísticas de los datos, los resultados se pueden ver en el cuadro (1). Se observa un gran parecido entre los datos de entrenamiento y los de validación.

Estadística	**Entrenamiento**	**Validación**
Número de Usuarios	2549	2549
Número de Artistas (ítems)	2631	2631
Total Ratings	534637	152424
Promedio ratings por usuario	209.74	59.79
Promedio de ratings por artista	203.2	57.93
Rating promedio	18.45	18.50
Rating desviación estándar	30.46	30.51
Máxima cant. rating por usuario	392	112
Máxima cant. rating por artista	383	122
Densidad (%)	7,97 %	2.27 %

Cuadro 1: Estadísticas del dataset Yahoo! Music.

En la figura (1) se pueden ver las distribuciones de usuarios sobre artistas y artistas sobre usuarios. La primera describe la popularidad de cada artista, cuántos usuarios han calificado a un determinado artista, mientras que la segunda nos describe la cantidad de artistas calificados por cada usuario. Vemos que las distribuciones de entrenamiento y validación se parecen mucho.

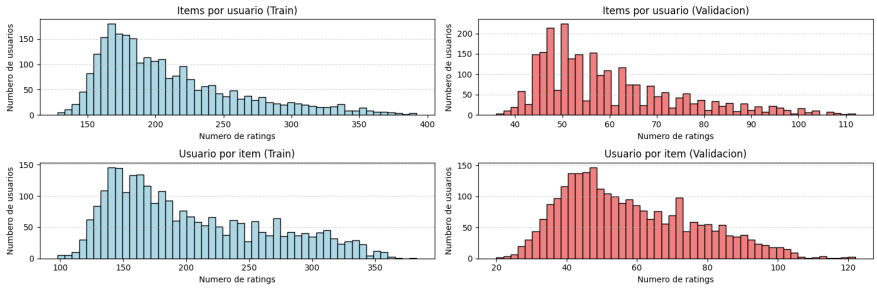

Figura 1: Distribución de usuarios y artistas en Yahoo! Music.

Se puede profundizar en la distribución de los ratings que los usuarios dan a los ítems dentro de su escala de 0 a 100 (El valor 255 fue transformado a 0, ya que ambos valores indican una mala evaluación del artista). Esta distribución se puede ver en la figura (2), en donde podemos apreciar una preferencia de los usuarios a dar un rating "entero", como 0, 10, 50, etc. en vez de un número específico, como 28. De hecho, se observa que el 91 % de los ratings en los datos de entrenamiento y validación corresponden a números cerrados, solo el 9 % corresponde al resto de posibles valores.

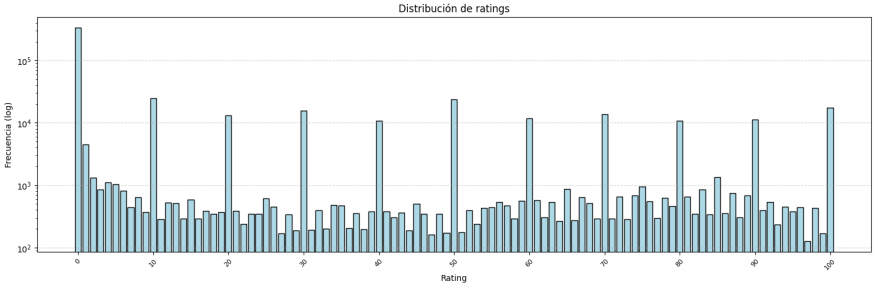

Figura 2: Distribución de ratings en Yahoo! Music.

Por último, se puede estudiar la distribución de los artistas a través de la variable "género". En la figura (3) se puede ver el la cantidad de reviews por género y el rating promedio para cada género en los datos.

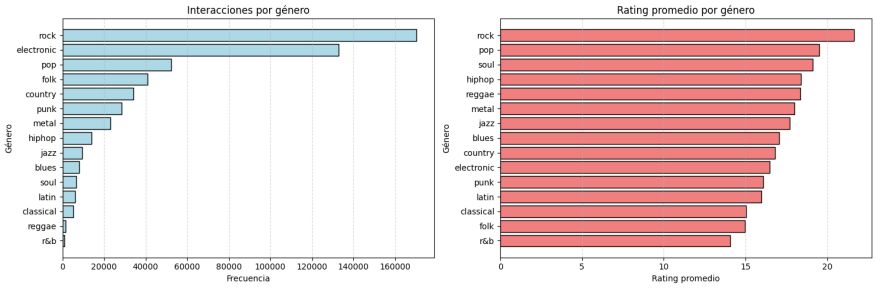

Figura 3: Distribución por géneros en Yahoo! Music.

Lo que se puede ver en la figura (3) es un gran desbalance de interacciones por género, siguiendo una curva exponencial. Esto puede generar problemas pues los sistemas de recomendación pueden preferir recomendar géneros más populares, olvidando los que se encuentran al fondo de la lista. Por otro lado, el rating promedio se mantiene relativamente constante considerando su escala, además, mantiene cierta correlación con la popularidad, géneros más populares suelen tener un rating promedio mayor.

1.2. Dataset Wikimedia Commons

En el cuadro (2) se encuentra un resumen estadístico de los datos utilizados en entrenamiento y validación. Se observa que la cantidad de imágenes aceptadas es muy baja, como se ve en la proporción de imágenes aceptadas sobre el total. La distribución de la aceptación de las imágenes se puede ver en la figura (4) en números absolutos, tenemos 67798 falsos y 8 verdaderos.

Estadística	**Entrenamiento**	**Validación**
Número de Usuarios	1079	1075
Proporción img. aceptadas	0.001	0.01
Promedio evaluaciones por usuario	62	9
Densidad (%)	65.96 %	16.47 %

Cuadro 2: Estadísticas del dataset Wikimedia.

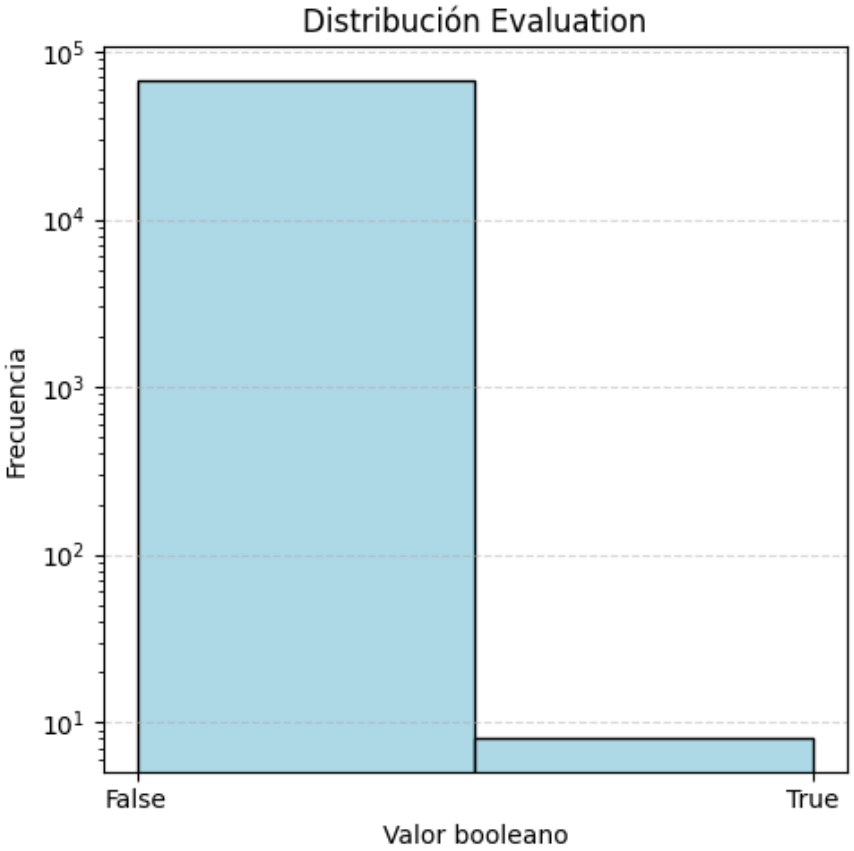

Figura 4: Distribución evaluación imágenes Wikimedia.

Por último, podemos estudiar la distribución de las evaluaciones a través del tiempo, como se ve en la figura (5). Para los datos de entrenamiento vemos un crecimiento en la cantidad de evaluaciones hasta 2016, mientras que en los datos de validación se observa la distribución tiene la misma forma, pero con alcanza el máximo en 2018

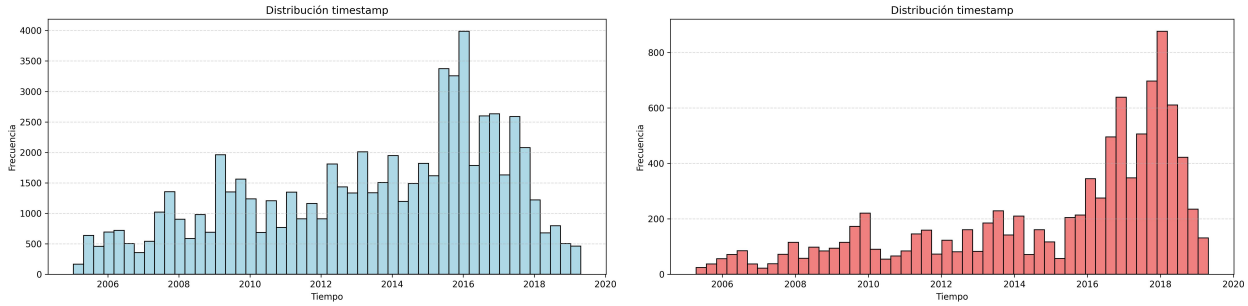

(a) Entrenamiento (b) Validación

Figura 5: Distribución timestamp y evaluación

2. Sistemas de Recomendación y Resultados

2.1. Recomendación de Música (Yahoo! Music)

2.1.1. Predicción de Ratings

Para el problema de predicción de rankings en el dataset de Yahoo! Music se implementaron 3 sistemas recomendadores: Item-based Collaborative Filtering, User-based Collaborative Filtering y Funk SVD. Los primeros dos algoritmos se basan en encontrar vecinos cercanos, mientras que el tercero es una factorización matricial de los datos.

En las figuras (6) a (9) se encuentran las métricas obtenidas para cada uno de estos modelos de predicción con el análisis de sensibilidad realizado sobre una muestra de parámetros. Para este apartado las métricas utilizadas fueron RMSE y MAE. Tanto en Item-based como en User-based Collaborative Filtering se probaron los valores $k = 2, 10, 20, 30, 40, 50$, en Funk-SVD se probaron cinco valores para el número de factores $(3, 25, 50, 75, 100)$. Para complementar el análisis de sensibilidad de Funk-SVD, también llevamos a cabo una comparación en rendimiento al modificar los parámetros de taza de aprendizaje y regularización, los resultados demuestran que el algoritmo es altamente sensible a los valores que pueden tomar estos hiperparámetros.

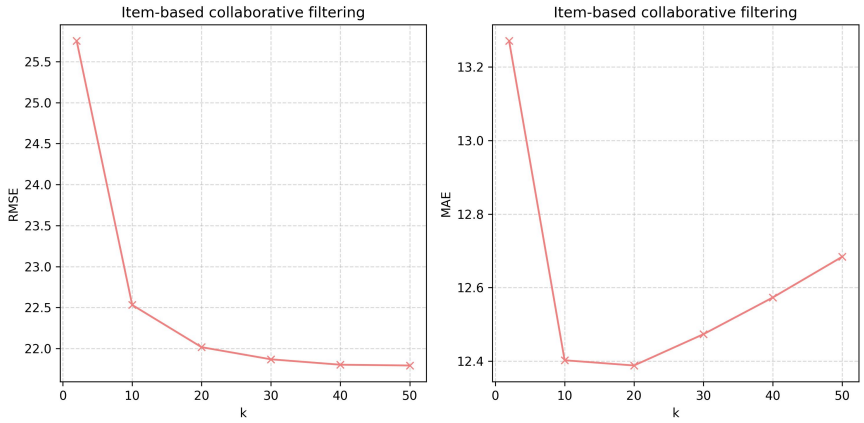

Figura 6: Métricas iKNN predicción.

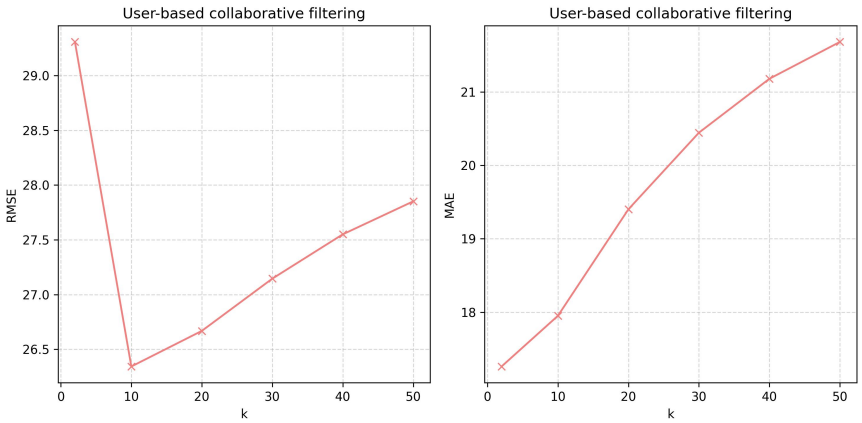

Figura 7: Métricas uKNN predicción.

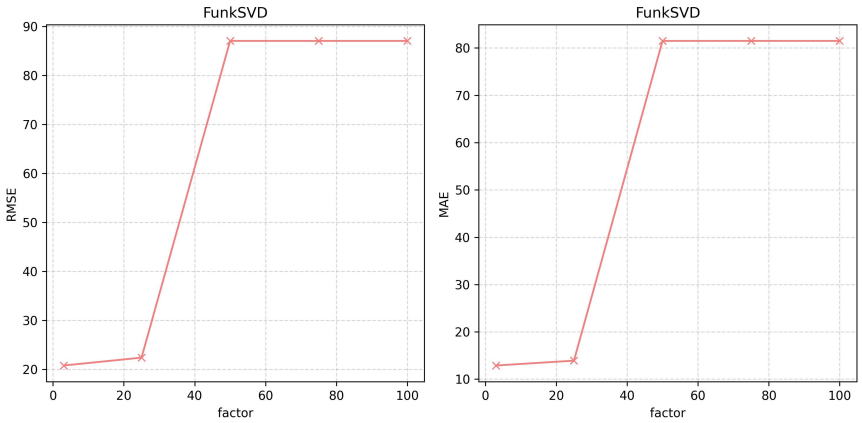

Figura 8: Métricas Funk-SVD predicción.

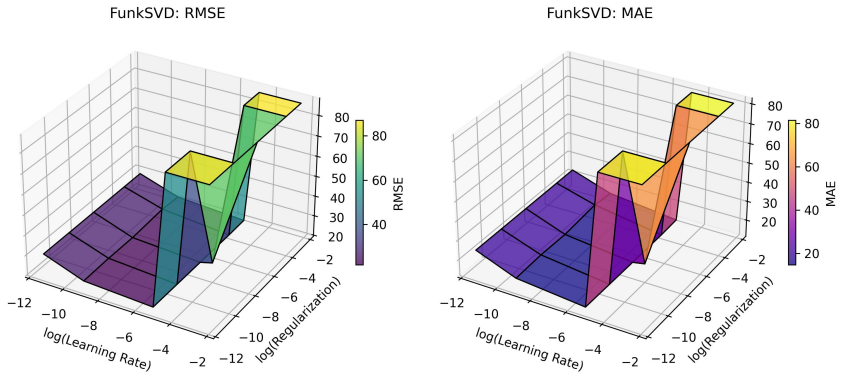

Figura 9: Funk-SVD: Sensibilidad a Learning Rate y Regularization.

En iKNN podemos ver que el error encuentra su valor más bajo con $k = 20$ considerando ambas métricas. Por otro lado, en uKNN el óptimo se encuentra en $k = 10$. Por último,

vemos que el error aumenta a medida que aumenta el número de factores, los menores valores para el error se obtienen con $n = 3$. Considerando los mejores valores obtenidos para cada modelo, vemos que los mejores resultados obtenidos fueron Item-Based Collaborative Filtering y Funk-SVD, los resultados difieren en menos de 0,5 puntos para ambas métricas, por lo que la diferencia entre ambos modelos puede ser considerada irrelevante. En el cuadro (3) se comparan los resultados obtenidos por los 3 modelos implementados.

Method	**RMSE**	**MAE**
uKNN	26.343	17.259
iKNN	21.793	12.388
SVD	20.781	12.896

Cuadro 3: Tabla comparación recomendaciones.

Es claro que el modelo User-Based obtuvo los peores resultados en ambas métricas.

2.1.2. Generación de Listas de Recomendación (Top-N)

Para generar listas de recomendación para los usuarios se probaron los algoritmos Random, Most-popular, ItemKNN y FunkSVD. Los primeros dos algoritmos pueden ser considerados un benchmark para evaluar la comparación de otros algoritmos más precisos, comparar el rendimiento frente a una lista aleatoria nos dice qué tan personalizadas son las recomendaciones, mientras que comparar con la lista Most-Popular nos da una idea de qué tan novedosas son, además de ver el impacto de los artistas más evaluados sobre las recomendaciones. Para implementar el algoritmo Random simplemente se consideró una muestra sobre los $artist_{id}$ que no habían sido ya reseñados por un usuario. De forma similar, para implementar Most-Popular se agruparon a los artistas de mayor a menor cantidad de reseñas, y se recomendó al usuario los artistas más reseñados que el usuario todavía no había reseñado. En cada método se consideraron listas de 10 usuarios, como se indica en el enunciado.

Para evaluar el desempeño de cada algoritmo se utilizaron las métricas Recall, nDCG y MAP, para evaluar la diversidad de las recomendaciones generadas, se calculó el promedio de la cantidad de géneros recomendados, y para medir novedad, se calculó la métrica self-information.

Para los algoritmos ItemKNN y FunkSVD se probaron los mismos parámetros que en predicción de rating ($k = 2, 10, 20, 30, 40, 50$ para iKNN y $3, 25, 50, 75, 100$ para FunkSVD). En las figuras (10) y (11) se pueden ver los resultados obtenidos en el análisis de sensibilidad para iKNN, en (12) y (13) se encuentra lo mismo para FunkSVD.

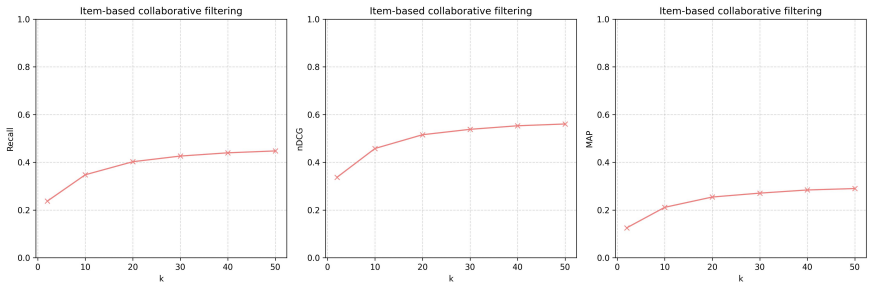

Figura 10: Métricas iKNN recomendación.

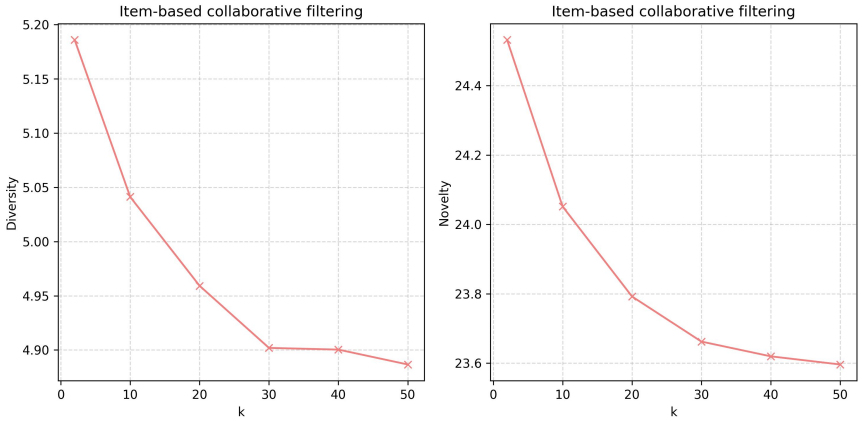

Figura 11: Métricas iKNN diversidad y novedad.

En iKNN, vemos que el parámetro óptimo es 50, y se observa en este rango que un mayor valor de k genera mejores resultados. Sin embargo, tanto en diversidad como novedad vemos lo contrario, a medida que aumenta el número de vecinos disminuye el rendimiento, esto puede deberse a que la optimización nos lleva a recomendar cosas parecidas, tanto entre si como a lo que el usuario ya vió antes. Es importante notar que el promedio de géneros recomendados no cambia mucho, varía de 5.2 a 4.8.

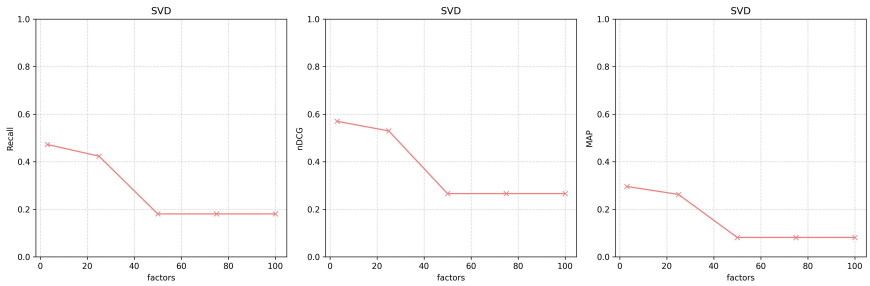

Figura 12: Métricas Funk-SVD recomendación.

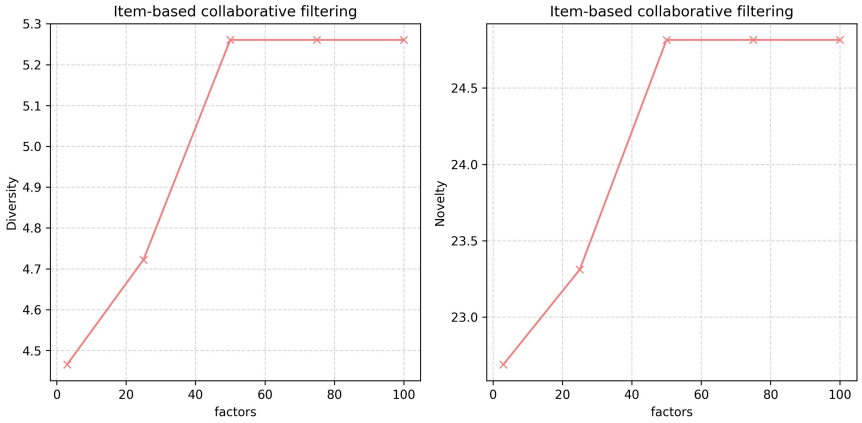

Figura 13: Métricas Funk-SVD diversidad y novedad.

Para FunkSVD vemos que, como en predicción, un menor número de factores entrega mejores resultados, además, el resultado se mantiene casi igual a partir de 50 factores, quizá a partir de ese punto el modelo empieza a recoger mucho ruido o valores nulos de los datos. De nuevo, lo contrario ocurre con la diversidad y novedad, vemos que si bien el algoritmo tiene peores métricas las recomendaciones que ofrece se vuelven más dispersas, novedosas.

En el cuadro (4) se encuentran los mejores resultados de iKNN y SVD junto a las métricas para los algoritmos Random y Most-Popular.

Method	**Recall@10**	**NDCG@10**	**MAP@10**	**Diversity**	**Novelty**
Random	0.003	0.006	0.001	5.395	25.818
Most-Popular	0.025	0.024	0.006	2.525	19.521
iKNN	0.447	0.560	0.290	5.185	24.531
SVD	0.472	0.570	0.295	5.260	24.814

Cuadro 4: Tabla comparación recomendaciones.

Vemos que los resultados son muy bajos, como era de esperar. Lo que nos es útil de este modelo son las métricas de diversidad y novedad, nos sirven como indicador. Si un modelo tiene diversidad o novedad similar a los del modelo aleatorio podemos decir que el primero tiene una alta diversidad o novedad. De la misma forma vemos que los resultados para Most-Popular son alrededor de 10 veces mejor (aunque siguen siendo bajos). Ahora, como estamos recomendando básicamente los mismos artistas a todos los usuarios se esperan valores bajos de diversidad y novedad.

Teniendo eso en consideración, vemos que modelos más personalizados (iKNN y SVD), obtienen resultados muy similares entre si y superan en rendimiento al resto de los algoritmos por un amplio margen. Además, vemos que tienen métricas de diversidad y novedad bastante altas, siendo comparables a las del modelo aleatorio.

2.2. Recomendación de Imágenes (Wikimedia)

A diferencia de los datos anteriores, en esta sección fue necesario emplear algoritmos que permitan hacer recomendaciones mediante información implícita. Para llevar a cabo

lo descrito anteriormente, empleamos los algoritmos "Alternating Least Squares" (ALS), "Bayesian Personalized Ranking" (BPR) y finalmente un algoritmo "Content Based", en donde utilizamos las imágenes en sí para generar listas de recomendaciones.

En la figura (14) se pueden observar los resultados de ALS mediante un análisis de sensibilidad, variando el parámetro de número de factores (n = (10, 50, 100, 150, 200, 250, 300)). Se puede observar que luego de 10 iteraciones, mientras mayor número de factores, se obtiene un mejor rendimiento en las métricas MAP, nDCG y Recall. Cabe destacar que aumentar el número de iteraciones no nos retornó mejores resultados.

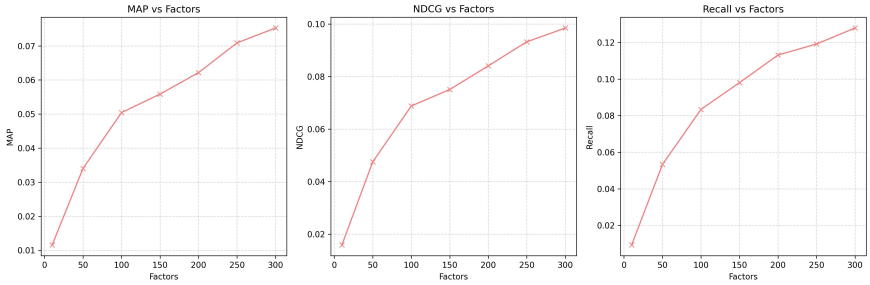

Figura 14: Métricas ALS recomendación.

Los resultados anteriores tienen un alto nivel de interpretabilidad en comparación con los resultados del algoritmo BPR. En la figura (15) se puede apreciar que a medida que aumenta el número de factores, no hay una tendencia clara sobre que valor retorna mejores o peores resultados, dificultado la elección del valor del parámetro óptimo. Solamente en la métrica Recall podemos afirmar que mientras mayor número de factores, se obtiene un peor valor de Recall, por lo que un valor razonable es 300 factores, ya que con este valor se maximiza MAP y nDCG, y se obtiene un Recall aceptable. Sin embargo, a diferencia del problema de interpretabilidad anterior, BPR tiene un comportamiento bastante más interpretable con respecto a los parámetros de taza de aprendizaje y regularización, lo cual se ve evidenciado por la figura (16).

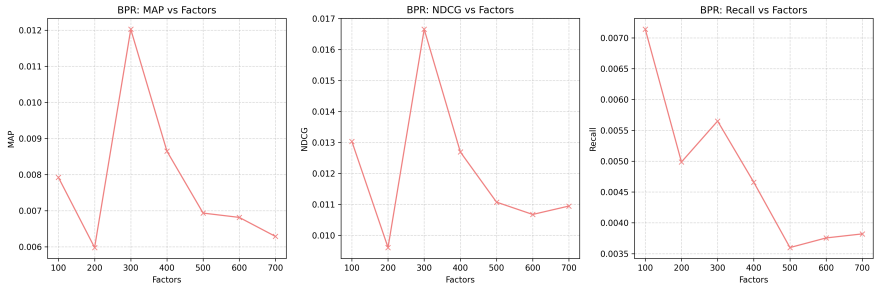

Figura 15: Métricas BPR recomendación.

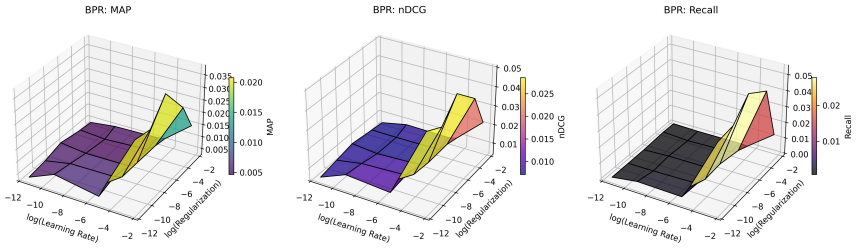

Figura 16: BPR: Sensibilidad a Learning Rate y Regularization.

Finalmente, creamos listas de recomendaciones utilizando los embeddings de las imágenes que provienen de una ResNet. Para lograr esto, calculamos la matriz de similitud de coseno entre todas las imágenes, luego, para cada usuario, hicimos retrieval de las imágenes que más se parezcan con respecto a las imágenes que el usuario ya había visitado, posterior a esto mantuvimos solamente el top 10 de imágenes más similares. Los resultados de este algoritmo se encuentran en el cuadro 5.

Method	**Recall@10**	**NDCG@10**	**MAP@10**
ALS	0.12	0.094	0.073
BPR	0.007	0.016	0.012
Content Based	0.0003	0.004	0.003

Cuadro 5: Tabla comparación recomendaciones.

3. Bonuses (Opcional)

3.1. Uso de calificación 255 (Yahoo! Music)

Para integrar estos datos se reemplazó la clasificación 255 por 0, esto vuelve extremadamente improbable que se le vuelva a recomendar a un usuario algo a lo que ya le dió un rating, especialmente uno negativo.

3.2. Uso de evaluación True/False (Wikimedia)

3.3. Análisis de Sustentabilidad (Green RecSys)

3.4. Competición